

Self-Supervised Learning of Graph Representations for Network Intrusion Detection

Integrantes

Luis Eduardo <lerf>

Renan Santana <rsc8>

Gustavo Santana <gsa4>

Marcos Antonio <maqvn>

Recapitulação


Motivação e justificativa


Cenário de IDS em Fluxos de redes:

- Escassez de dados rotulados
- Rápida evolução dos ataques cibernéticos (aparecimento de ataques zero day)

Problemas dos modelos:

- Supervisionado: Exigem constante retreino e são focados em ataques específicos
- Não supervisionados: Não conseguem capturar o contexto estrutural





E-GraphSAGE
Aprende estrutura
local

Máscara
Funciona como um
dropout

Transformer
Aprende a estrutura
global

Principais Limitações



Ataques de Infiltração

Dificuldade em detectar ataques de payload via email, cujo comportamento topológico inicial mimetiza o tráfego normal.



Visão de Host Único

Baixa eficácia em monitoramento de máquinas isoladas devido à falta de um contexto de rede amplo.




Topologias Instáveis

Degradação de performance em redes sujeitas a mudanças estruturais abruptas e constantes.



Single host

O que é um cenário de single host em IDS?




O que foi proposto

Arquitetura:

- Manteve-se a arquitetura utilizada pelo modelo

Modelagem dos dados

- Abordagem direta: todas as amostras foram construídas a partir de um par de hosts artificiais e as chamadas de sistema foram atributos das arestas
- Modificação: Cada identificador de system call é representado como um nó no grafo. Enquanto as arestas foram modeladas de forma direcionada com base em chamadas consecutivas de system calls



IMPACTO DA ESTRATÉGIA DE MODELAGEM NA PERFORMANCE DO GRAPHIDS.

Abordagem	Macro F1-score	PR-AUC
Abordagem Inicial	0.4945	0.1151
Abordagem com Modificação	0.6816	0.3420



Topologia Instável

Descrição do Problema


O GraphIDS é excelente para detectar ameaças **Zero-Day**, mas sofre de um engessamento arquitetural na prática.

Em cenários reais, a topologia da rede **não é estática**:

- Servidores são provisionados;
- Contêineres são destruídos;
- Novos fluxos legítimos surgem;

Os pesos do Transformer são **offline** (congelados após o treino). Padrões topológicos inéditos causam alto erro de reconstrução.

IDS confunde a evolução natural da infraestrutura com um ataque cibernético. Gera vários **falsos positivos**.



Assumir uma topologia estável foi uma simplificação utilizada:

- Datasets comuns são fotografias estáticas de **sem evolução temporal**
- Rastrear a evolução topológica pode não ser trivial
- **Não interfere** no propósito principal
 - Provar que a junção *End-to-End* de GNNs com Transformers mascarados é **superior** para a detecção

Problemas envolvidos:

- **Esquecimento:** Ao fazer fine-tuning com novos padrões topológicos, o modelo pode esquecer o que é um ataque. O ajuste contínuo precisa equilibrar adaptação com retenção da detecção de ameaças.
- **Custo Computacional:** Manter o grafo dinâmico e rodar NeighborSampler a cada fluxo e retreinar periodicamente exige CPU/RAM muito acima do batch original.
- **Data Poisoning / Evasão:** Se o buffer de tráfego benigno aceita tudo, um atacante pode inundar a rede com tráfego legítimo de novos hosts para mascarar o ataque real, ou envenenar o buffer para que o threshold fique permissivo.

Solução Proposta

Dynamic Graph: Grafo que evolui com o tráfego

- `add_edge(ip_src, ip_dst, features, timestamp)` → adiciona aresta
- `remove_stale_edges(1h)` → arestas velhas expiram
- `get_current_graph()` → subgrafo ativo agora


Nós sem arestas também são removidos. O grafo reflete **sempre o estado atual** da rede.

Fine-Tuning por janelas: Continual learning

- Em vez de treinar uma vez, o modelo treina **janela por janela** (1h de tráfego cada, stride 30min). As primeiras 60% das janelas são treino; as 40% restantes são avaliação com threshold adaptativo.

Adaptive Threshold

- $$\text{threshold}(t) = \underset{\text{peso} \uparrow 10\%}{\alpha} \times \text{threshold_janela} + (1-\underset{\text{peso} \uparrow 90\%}{\alpha}) \times \text{threshold}(t-1)$$



Métricas de avaliação do método no dataset NF-UNSW-NB15-v3
com topologia dinâmica

Abordagem	Macro F1-score	PR-AUC
Streaming	0.000	0.000